ISUP

L’IA pour analyser les données non structurées à l’ère de l’IA générative

Présentation

Kent Aquereburu

Yolan Honoré Rougé

Données non structurées

- La majorité des données d’entreprise sont non structurées
- Emails, PDF, images, audio,
- Les informations les plus précieuses s’y trouvent souvent

- Pas de schéma prédéfini
- Données et formats hétérogènes (tableaux, images, texte)
- Analyse manuelle impossible à l’échelle

Transformer la donnée pour les modèles d'IA

Besoin de transformer les données dans un format standard adapté pour les modèles d'IA

Docling : Un framework combinant plusieurs technos pour convertir tout document en **texte exploitable par les modèles d'IA (IA classique ou IA generative LLM)**

https://github.com/docling-project/docling

Principales techniques d’analyse

- OCR pour documents scannés et Computer Vision pour détecter la structure des pdfs
- NLP pour le texte (extraction champs specifiques, catégorisation)
- Speech-to-Text pour transcrire l’audio en texte (analyse d’appels clients)
- Une fois la donnée structurée, nous pouvons appliquer différentes des méthodes classiques de Machine Learning ou des méthodes avancées et plus récentes de type LLM & RAG

LLM & RAG

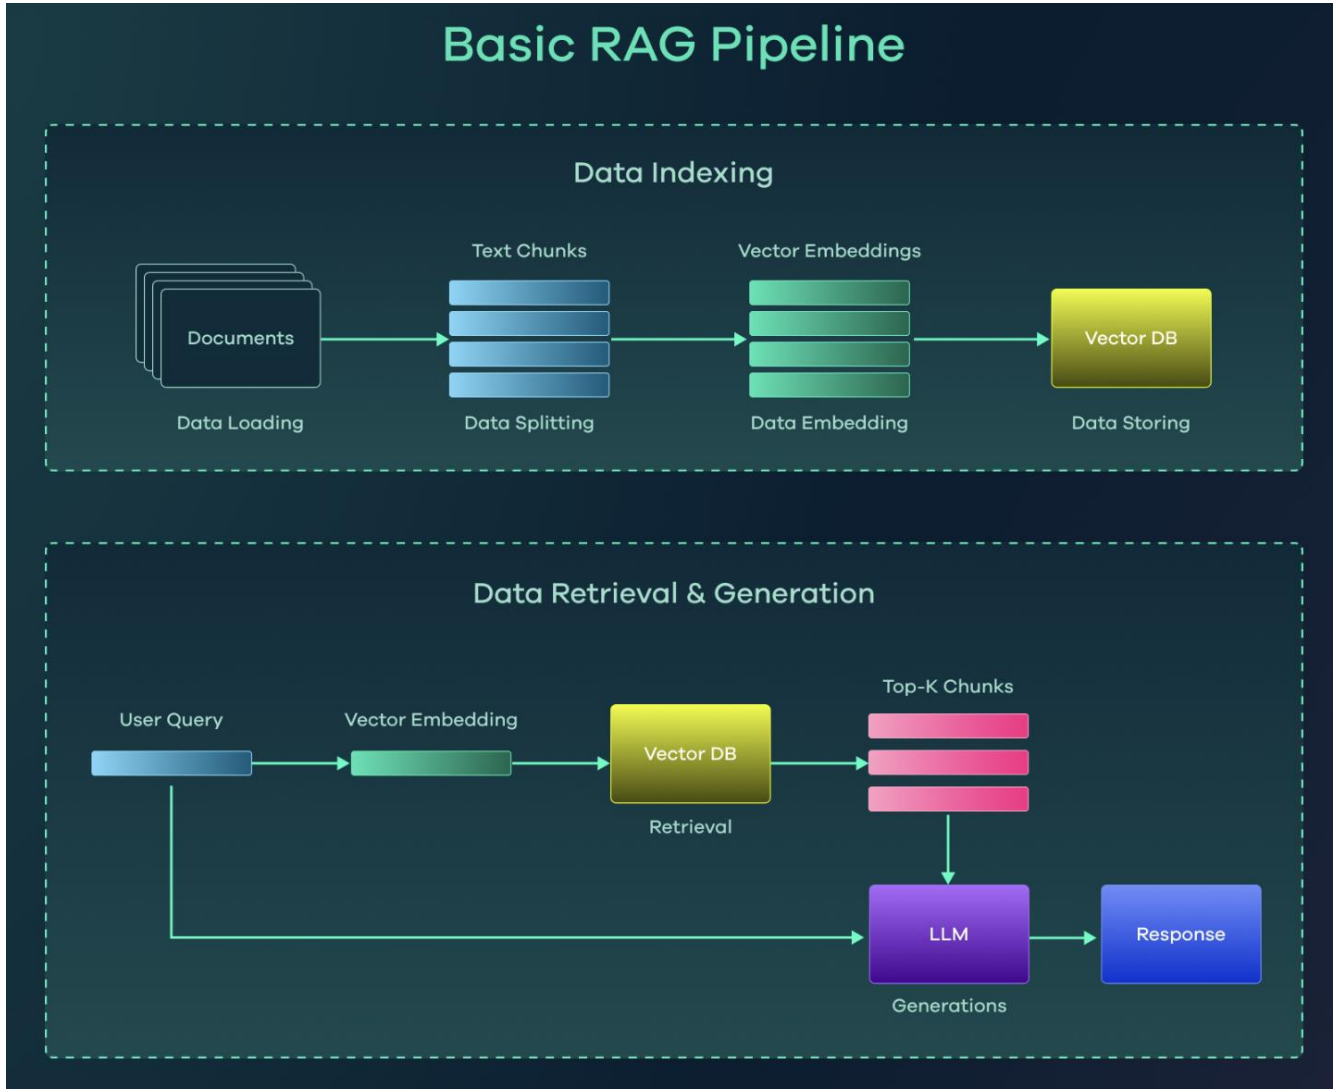

- RAG = Recherche + Génération
- Réponses basées sur les documents + citations
- Réduction des hallucinations

- Possible d'utiliser des modèles Open Source en local ou des modèles (API) proprietaires (Open AI)

Exemple pratiques en Python

- Preprocessing de documents pdf
- Preprocessing de fichiers audio mp3
- Applications
  - RAG : questions sur des conditions generales
  - Analyse de verbatims clients pr détecter les thèmes principaux